Asistente Bursátil para el inversor value colombiano — Entrega 1

Louis Gualtero · MINE-4101 Ciencia de Datos Aplicada · Universidad de los Andes

Repositorio: https://github.com/louis97/asistente-financiero/tree/entrega-1 · **Video:** (pendiente)

1. Problema y negocio

El inversor value colombiano que compra acciones de EE.UU. actúa como enrutador manual de datos: usa un screener, otra pantalla para fundamentales y otra para el gráfico, y no tiene dónde anotar sus decisiones. Con la evidencia cualitativa de una entrevista y un formulario (un participante más el autor; evidencia exploratoria, no representativa): **de 2 a 15 cambios de pantalla por activo**, **2 a 3 horas** para actualizar el análisis tras cada reporte trimestral y riesgo medido "a ojo". El contexto crece: el volumen del Mercado Global Colombiano pasó de $1,60 a $3,75 billones entre 2024 y 2025 (+134 %, BVC). Objetivo: una vista única con niveles de compra y venta, y probabilidades explicables. KPIs: tiempo por activo < 5 min, 1 cambio de pantalla, latencia tras reporte ≤ 1 día, 100 % de decisiones registradas.

Detalle: 01_negocio.md

2. Ideación y mockup

El producto entrega seis niveles definidos por el usuario (tres de entrada, tres de salida), cada uno en precio y en múltiplo, con tres lecturas: fundamental (percentil en la historia y la industria), técnica (probabilidad de un SVM frente a su línea base, la tasa de toque por decil de σ) y probabilística (Monte Carlo con y sin el factor del sector), más un panel de riesgo (volatilidad, VaR/ES, beta, drawdown, Merton). Los niveles por múltiplo se recalculan cuando EDGAR publica un reporte (precio = múltiplo × EPS). El prototipo usa valores ilustrativos. **La validación con el stakeholder está pendiente**: el guion está listo y el registro se completará tras la sesión; no se reportan resultados de validación.

Detalle: 02_ideacion.md

3. Aspectos éticos y legales

Los riesgos altos son tres. **Regulación de la asesoría** (Ley 964 de 2005): el producto no recomienda "compra" ni "venta", los niveles los define el usuario y cada pantalla dice que no es asesoría. **Transparencia**: SVM lineal con coeficientes legibles y probabilidad siempre junto a su línea base y su error histórico. **Look-ahead y data snooping**: fundamentales con fecha filed, ventana expansiva, purga y embargo. Además: anonimización del participante (Ley 1581 de 2012), términos de uso de yfinance, EDGAR y Damodaran, y sesgo de supervivencia de 30 emisores vigentes.

Detalle: 03_etica_legal.md

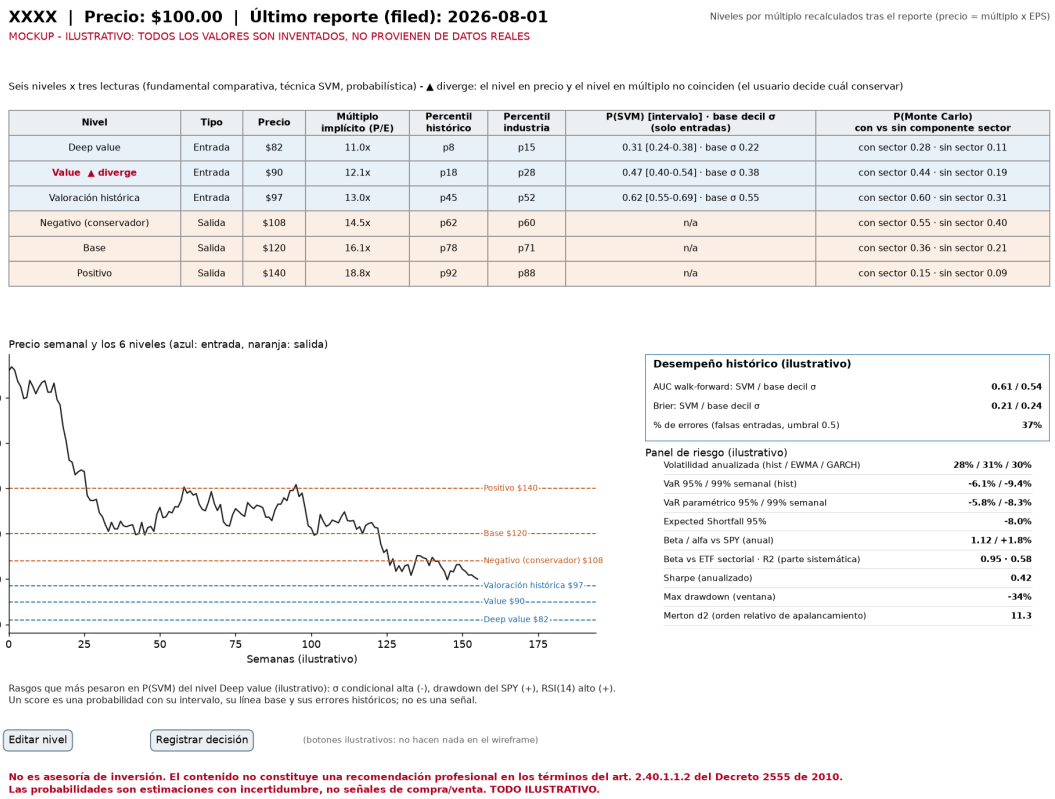


Figura 1: Mockup del dashboard (valores ilustrativos)

4. Enfoque analítico

Tres preguntas de negocio (¿es razonable el nivel?, ¿compro ya o espero?, ¿qué tan probable es el objetivo?) se traducen en hipótesis con H0 y H1 que se pueden refutar: técnicas (HT0 caminata aleatoria, HT1 SVM frente a la tasa de toque por decil de σ, HT2 señal de indicadores), fundamentales (HF1 y HF2 reversión de múltiplos) y probabilísticas (HP0 colas pesadas, HP3 efecto del sector). La etiqueta es una **triple barrera solo-largo** (±k·σ, horizonte de N semanas; en el EDA se eligió k = 1, N = 12). Validación **walk-forward con purga y embargo**, con cuatro líneas base obligatorias (tasa empírica de toque por decil de σ con etiquetas ya resueltas antes de t y cortes expansivos, que decide HT1; clase mayoritaria; regresión logística; momentum 12-1) y el GBM con deriva como referencia teórica y reglas de decisión fijadas de antemano: una hipótesis solo se declara apoyada si cumple su regla (IC bootstrap que excluye el valor nulo), con cuatro estados: apoyada, no apoyada, no concluyente y preparada. Todo es asociativo, no causal.

Detalle: 04_enfoque_analitico.md

5. Recolección y calidad de datos

Tres fuentes gratuitas: yfinance (precios semanales y mensuales desde 2009), SEC EDGAR (hechos XBRL con fecha filed) y Damodaran (múltiplos por industria). Universo: 30 acciones grandes de EE.UU. y 4 ETF (SPY, XLK, XLP, XLF), con 27 326 filas en el panel semanal. Calidad: precios sin nulos, duplicados ni semanas faltantes; 73 saltos > 5σ que son movimientos reales. La utilidad bruta está presente en solo 14 de 30 emisores (ausente en 16) y las financieras no tienen utilidad operativa. Las cifras de EDGAR coinciden en 6 de 6 con el 10-K de AAPL, KO y JPM (HF5 apoyada).

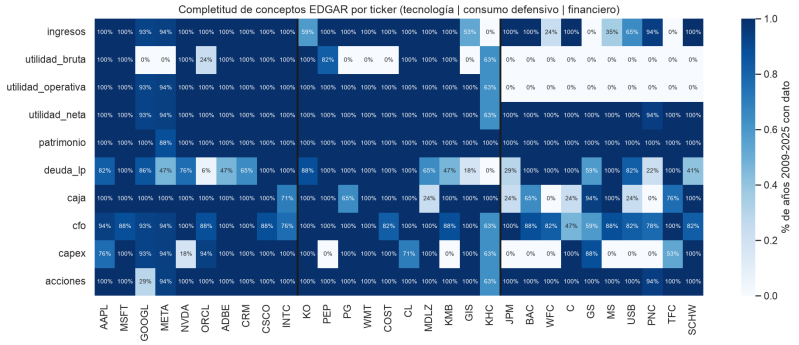


Figura 2: Completitud de conceptos de EDGAR

Detalle: 05_diccionario_datos.md · nb 02

6. Análisis exploratorio (EDA)

Volatilidad y colas. La volatilidad se agrupa y las colas son pesadas: curtosis en exceso mediana 4.63, v mediano 4.15 (v < 10 en 34 de 34 series); GARCH(1,1)-t supera a la volatilidad constante fuera de muestra en 28 de 34 series. Un GBM normal no describe el riesgo (HP0 y HT4 apoyadas).

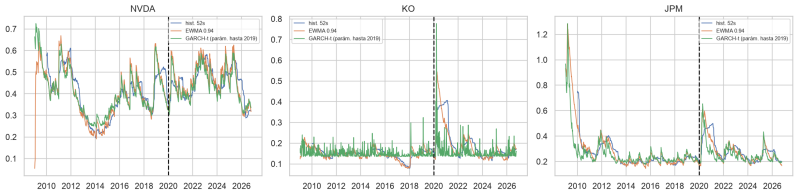


Figura 3: GARCH-t frente a EWMA

Dirección del precio. ADF no rechaza la raíz unitaria en 33 de 34 log-precios y |ρ lag 1| mediana es 0.068, pero solo 15 de 30 tickers pasan ADF, KPSS y Ljung-Box a la vez (HT0 no apoyada; con Ljung-Box sobre residuos de GARCH-t pasarían 26 de 30, desviación que la regla no contempla). Con k = 1, N = 12, un GBM con μ = 0 sobreestima la clase 1 en 9.5 pp (0.178 observada frente a 0.2735) y, con deriva pasada, en 0.8 pp, pero P_GBM no está calibrada (pendiente b = −0.294, IC −0.641 a −0.011; HT0 calibración no apoyada). Como b < 0 indica una AUC del GBM por debajo de 0.5, el GBM queda como referencia teórica y el rival que decide HT1 es la tasa por decil de σ (cambio fijado antes de evaluar HT1).

Indicadores técnicos. No separan las clases por sí solos: AUC por indicador de 0.496 a 0.514, ningún IC por bloques excluye 0.5. Por régimen sube a 0.64–0.79 solo en COVID y 2022 (puntos sin IC), eventos únicos; el 0.95 de 2009 es un punto sin IC y refleja el timing de un evento (HT2 no concluyente; HT3 no apoyada, pues el signo no es estable en todos los indicadores: vol_rel20 2/5 regímenes, con signos puntuales sin IC; por mayoría sería apoyada y, como todos los IC incluyen 0.5, no concluyente es una lectura defendible).

Sector. El IC de β excluye 0 en 30 de 30 y el R^2 mediano del modelo de índice único con el ETF sectorial es 0.525 (financieras 0.700, tecnología 0.387); las industrias se agrupan solas (ARI 0.898) (HP3 apoyada; en tecnología, periodo Reciente, el R^2 es 0.283).

Múltiplos y VaR. Solo 7 de 29 tickers muestran reversión del P/E o P/B (HF1 no apoyada) y 10 de 29 con el múltiplo relativo (HF2 no apoyada); calidad y valoración (HF3) y d2 de Merton (HF4) no son concluyentes. El VaR 95 % fuera de muestra tiene 7.49 % de excepciones con

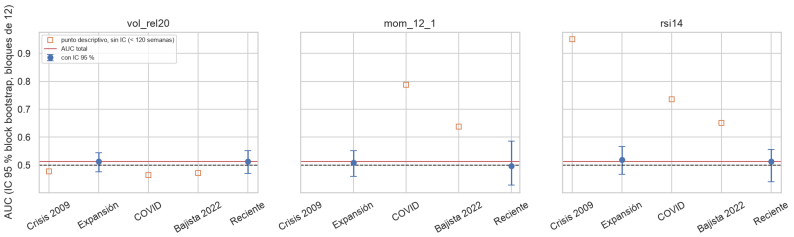


Figura 4: AUC por régimen

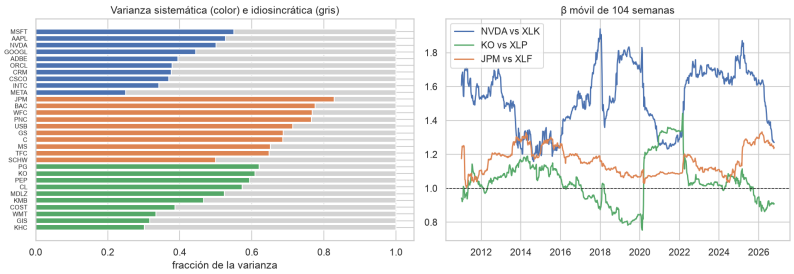


Figura 5: Índice único: R^2 por ticker

GARCH-t y 6.78 % con el histórico, frente al 5 % esperado; GARCH-t es adecuado en 14 de 30 (HP1 no apoyada).

Detalle: 03_eda_series · 04_eda_relaciones · 07_conclusiones.md

7. Conclusiones e insights

El EDA no muestra que los indicadores técnicos, por sí solos, separen las clases; la probabilidad de la etiqueta depende de σ (de 20.6 % en el decil 1 a 7.8 % en el decil 10) y del régimen. Decisiones de diseño: etiqueta k = 1, N = 12; simulación con GARCH-t e innovaciones t, no GBM normal; rival del SVM: la tasa de toque por decil de σ (etiquetas resueltas antes de t), con el GBM con deriva ≤ t solo como referencia teórica porque no está calibrado; 5 indicadores retenidos + σ condicional y rasgos de régimen calculados hacia atrás; múltiplos solo como contexto; VaR 99 % histórico con advertencia, pendiente de backtest. **Limitaciones**: muestra desde 2009, pocos eventos de régimen, sesgo de supervivencia y fundamentales incompletos. **Próximas acciones**: entrenar el SVM con walk-forward (HT1 y HP2 quedan preparadas, no probadas; se espera una mejora pequeña o nula), añadir rasgos de régimen calculados hacia atrás, construir el Monte Carlo y validar el mockup con el stakeholder.

Detalle: 07_conclusiones.md