Asistente bursátil para el inversor value colombiano — Entrega 1

Louis Gualtero · MINE-4101 Ciencia de Datos Aplicada · Universidad de los Andes

Repositorio: https://github.com/louis97/asistente-financiero · **Rama de entrega:** main tras la fusión del 18 de octubre · **Video:** pendiente de subir · **Trabajo individual autorizado por el profesor.**
Convención. Las referencias del tipo "nb04 §2.7" remiten al notebook 04, sección 2.7, del repositorio.

1. Problema y entendimiento del negocio

El inversor value colombiano que compra acciones de EE.UU. (una acción es una fracción del capital de una empresa; "value" significa que paga poco por cada dólar de utilidad) actúa hoy como enrutador manual de datos: usa un *screener* para filtrar empresas, otra pantalla para los fundamentales (ratios como el P/E, precio sobre utilidad por acción) y otra para la gráfica, y no anota sus decisiones. La evidencia cualitativa (entrevista y formulario con un participante, más el autor; muestra no representativa) reporta **2 a 15 cambios de pantalla por activo** y **2 a 3 horas** para reprocesar el análisis tras cada reporte trimestral, y el riesgo se mide "a ojo". El contexto crece: el volumen del Mercado Global Colombiano pasó de $1,60 a $3,75 billones de 2024 a 2025 (+134 %, BVC 2026) y la SFC reporta un aumento de 87 % en inversionistas desde 2023. **El alcance de la entrega 1 es una industria piloto, consumo defensivo** (alimentos, bebidas, aseo personal y del hogar, y tabaco: bienes que se compran en cualquier fase del ciclo), con 21 empresas del XLP (el ETF sectorial, un fondo que cotiza como una acción y agrupa a las empresas del sector) con historia desde 2009, más el SPY (ETF del mercado) y el XLP. KHC queda fuera porque sus precios empiezan en 2015. Los KPI del producto son tiempo por activo menor que 5 minutos, un cambio de pantalla, latencia tras un reporte de un día o menos y 100 % de decisiones documentadas; la línea base de los KPI 1, 2 y 5 queda **sin obtener** (la validación del 2026-10-18 fue asíncrona y el participante no respondió el formulario; §7).
Detalle: https://github.com/louis97/asistente-financiero/blob/main/docs/entrega_1/01_negocio.md

2. Ideación y mockup

El producto entrega, para cada ticker, **seis niveles definidos por el usuario** (tres de entrada y tres de salida), en precio y en múltiplo. Cada nivel trae tres lecturas: **fundamental** (percentil histórico y de la industria del P/E, del P/E normalizado y de los ratios de calidad; el percentil responde "entre los valores pasados, ¿en qué puesto queda el de hoy?"), **técnica** por SVM lineal (*support vector machine*: un modelo que aprende a separar casos positivos de negativos y entrega una probabilidad) con horizonte de 60 días hábiles frente a su línea base por decil de volatilidad (solo entradas) y **probabilística** por simulación que remuestrea bloques de semanas de la acción y del XLP a la vez para construir futuros alternativos con la historia reciente (solo salidas). Un panel de riesgo descriptivo muestra cinco cifras: volatilidad anualizada (σ, dispersión típica del retorno),

percentil 5 semanal, caída máxima histórica, frecuencia de caídas fuertes y dependencia del sector. Los niveles por múltiplo se recalculan cuando la SEC publica un reporte nuevo; para tickers fuera del piloto, el panel se marca “industria no validada” y las probabilidades llevan advertencia. El **mockup v2** incorpora el feedback del inversor del 2026-10-18 (sesión asíncrona por mensajería): una franja “Cómo leer esta pantalla” con 8 definiciones de una línea, P/E y P/B en columnas separadas, una columna “ % vs. precio actual” y un panel de riesgo más espaciado; el “veredicto” que pidió el participante no se incorpora porque choca con la regla de no recomendar.

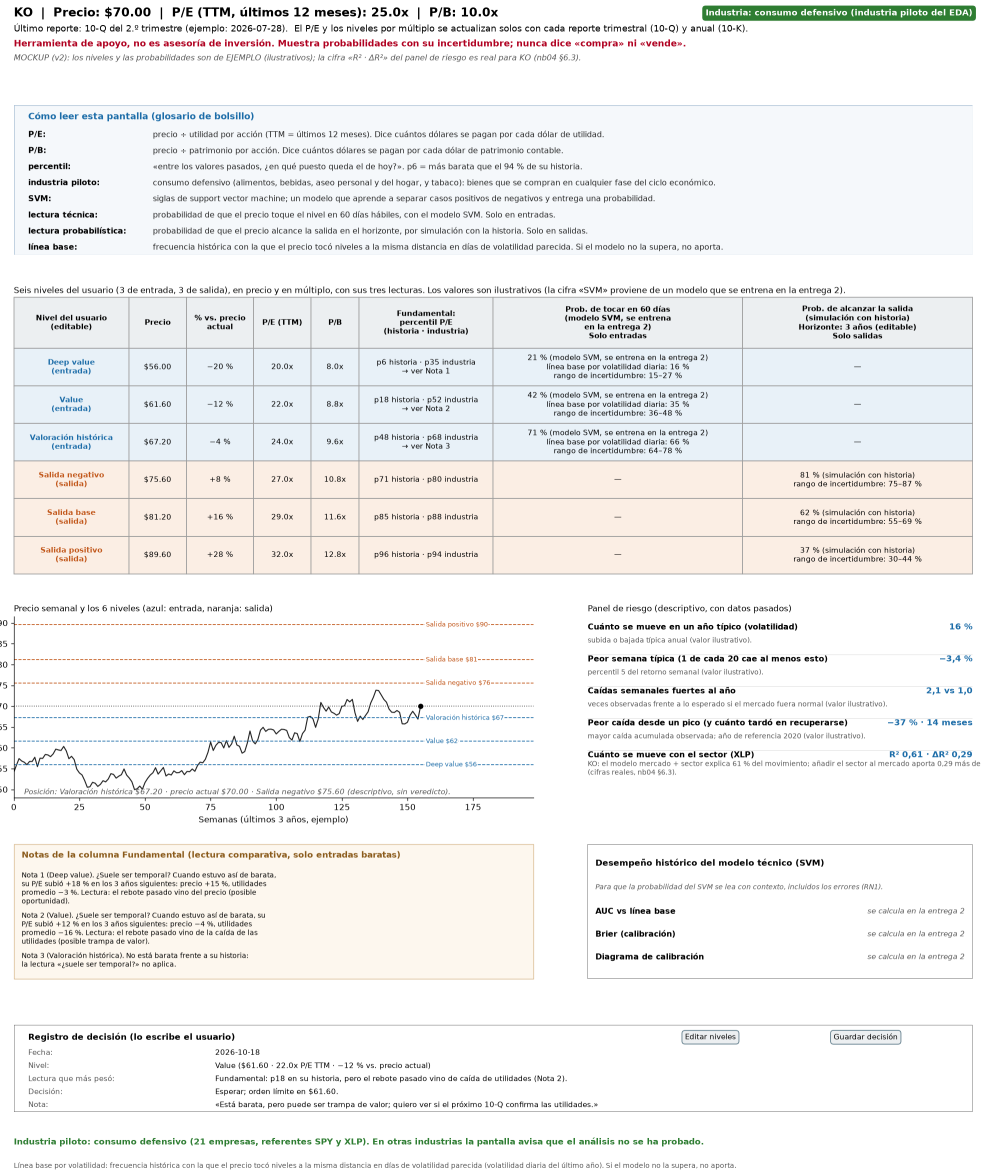


Figura 1: Mockup v2 del dashboard (valores ilustrativos). La franja “Cómo leer esta pantalla” define 8 términos (P/E, P/B, percentil, industria piloto, **SVM**, lectura técnica, lectura probabilística, línea base) en una línea cada uno; la columna “Prob. de tocar en 60 días” muestra 21 %, 42 % y 71 % (modelo SVM, se entrena en la entrega 2) frente a la línea base por decil de volatilidad diaria (16 %, 35 % y 66 %), y la “Prob. de alcanzar la salida” muestra 81 %, 62 % y 37 % por simulación con la historia. Las notas 1 a 3 bajo la tabla llevan la lectura “¿suele ser temporal?”. El panel de riesgo trae 5 cifras descriptivas; el recuadro “Desempeño histórico del modelo técnico (SVM)” aparece marcado “se calcula en la entrega 2”. La marca del precio actual sobre el gráfico (“entre Valoración histórica $67.20 y Salida negativo $75.60”) es descriptiva, sin veredicto.

Detalle: https://github.com/louis97/asistente-financiero/blob/main/docs/entrega_1/02_ideacion.md

3. Aspectos éticos y legales

Tres riesgos quedan altos tras mitigar. **Regulación de la asesoría** (Ley 964 de 2005 y Decreto 2555 de 2010): la asesoría de inversión está reservada a entidades vigiladas por la SFC, y el producto evita entrar a ese perímetro porque no recomienda compra ni venta, no perfila al usuario y lleva en cada pantalla la leyenda del artículo 2.40.1.1.3. **Transparencia y explicabilidad** de la probabilidad del modelo técnico: se usa un SVM lineal con coeficientes legibles, la probabilidad siempre aparece junto a su línea base y a su desempeño histórico, y se publica la lista explícita de técnicas no cubiertas en clase. **Look-ahead y data snooping** (que el análisis vea datos del futuro, o que se pruebe de todo hasta encontrar algo): se usa la fecha filed (día en que la SEC publica el reporte), una ventana expansiva (solo datos hasta t) y 15 pruebas declaradas antes de ejecutar (Bonferroni en P4 y Holm como sensibilidad). También se cuida la anonimización del participante (Ley 1581 de 2012), los términos de uso de yfinance, SEC EDGAR y Damodaran, el sesgo de supervivencia de 21 emisores vigentes y la marca “industria no validada” fuera del piloto. **Técnicas no cubiertas en clase (15 en total):** bootstrap por bloques de fechas, nulo calibrado por simulación, ΔAUC con regresión logística, errores estándar agrupados por empresa, Brier y calibración, análisis de potencia (MDE), EPS TTM (utilidad por acción de los últimos 12 meses) a partir de 10-Q, SVM, simulación por bloques, Bonferroni, Holm, VIF, prueba F de modelos anidados, Mann-Whitney y clustermap; el detalle con la justificación de cada técnica está en el documento enlazado abajo.
Detalle: https://github.com/louis97/asistente-financiero/blob/main/docs/entrega_1/03_etica_legal.md

4. Enfoque analítico

El trabajo responde a **seis preguntas de negocio con una hipótesis cada una**. Cada hipótesis sigue la misma secuencia: umbral práctico fijado antes, H0/H1 y α = 0,05, prueba con su matriz de supuestos, estimación con intervalo de confianza al 95 % (IC95: rango en el que cae el estimado el 95 % de las veces si se repitiera el experimento, construido por bootstrap, un remuestreo que no supone una forma teórica), y dos decisiones. La **estadística** es “se rechaza H0” si el IC95 no incluye el valor nulo y “no se rechaza H0” si lo incluye. La **de negocio** es “accionable” si el límite inferior del IC95 supera el umbral, “efecto real, magnitud incierta” si se rechaza H0 pero el IC95 cruza el umbral, y “no accionable” en los demás casos. Lenguaje de asociación, nunca de causa. La tabla reúne cada pregunta con lo que **decide en la herramienta** —qué pieza del producto depende de la respuesta—, el umbral, el estimado con IC95 y las dos decisiones. Un umbral de 0,03 **anualizado en log** equivale a cerca de 9 % acumulado en tres años; “anualizado en log” es el cambio porcentual promedio por año, medido con logaritmos para que los años se puedan sumar.

P.	Pregunta	Decide en la herramienta	Umbral	Estimado · IC95	Decisión
P1	¿Caídas semanales fuertes más que una normal igual?	Panel de riesgo: frec. de caídas fuertes.	3,83 % sem.	3,08 % · [2,46; 3,92] %	no se rechaza H0 · no acc.
P2	¿El quintil barato sube su P/E norm. más que el caro a 3 años?	Lectura fundam. de entradas: percentil del P/E norm.	+0,03 anual. log	+0,153 · [+0,091; +0,221]	se rechaza H0 · acc.
P3	¿El quintil barato gana al XLP a 3 años?	Exceso sobre XLP no entra como señal.	+0,05 anual. log	+0,006 · [−0,032; +0,049]	no se rechaza H0 · no acc.
P4	¿Algún indicador técnico mejora la AUC base?	Lectura técnica: SVM solo con variables de magnitud.	+0,01 ΔAUC (×7)	7 IC95 cruzan 0; dist_sma50 −0,024 · [−0,066; +0,026]	no se rechaza H0 (×7) · no acc.
P5	¿XLP agrega ΔR^2 al SPY semanal?	Panel de riesgo (dep. del sector) y simulación acción + XLP.	+0,05 ΔR^2	0,225 · [+0,175; +0,291]	se rechaza H0 · acc. (confirm.)
P6	¿La turbulencia se agrupa?	Lectura probabilística: simulación por bloques de semanas.	0,30	P(T|T) diaria 0,305 · [0,275; 0,340]	se rechaza H0 · magnitud incierta

{Abreviaturas de la columna “Decisión”: acc. = accionable (el límite inferior del IC95 supera el umbral); no acc. = no accionable; (confirm.) = confirmatoria (la propiedad se usó también para elegir la industria piloto; §7).}

La lectura de P2 incluye una **advertencia descriptiva de posible deterioro de utilidades** (compatible con trampa de valor); los niveles de P6 se expresan en **k · σ252 diaria** (volatilidad del último año); y P5 justifica analizar una industria a la vez.

P1 en palabras simples. Una caída fuerte es una semana en que la acción cae más de 2 veces su volatilidad semanal típica del último año ($z < -2$, donde z es el retorno sobre su σ reciente). Si los retornos siguieran una distribución normal (campana de Gauss) con esa volatilidad conocida, pasaría en el 2,3 % de las semanas; como la volatilidad se estima con el pasado y no se conoce, la tasa comparable, calibrada por simulación con la misma receta, es ≈ 2,55 %. P1 pregunta si en consumo defensivo pasa más que eso: si no, el panel no infla la “frecuencia de caídas fuertes” artificialmente.

P/E normalizado en palabras simples. El P/E es precio sobre utilidad por acción (EPS). El P/E normalizado es precio dividido por el **EPS promedio de los últimos 3 años** (utilidad neta de los 12 trimestres ya publicados ÷ 3 ÷ acciones). Promediar 3 años evita que un solo año excepcional —malo o bueno— haga parecer barata o cara una acción. “Barata frente a su historia” se opera como el quintil con el P/E normalizado más bajo de la industria en esa fecha.

Diseño experimental. La **etiqueta** vale 1 si el precio toca, dentro de los próximos **N = 60 días hábiles**, un nivel ubicado a **k = 1 volatilidad diaria por √N por debajo** del precio actual (el nivel superior es simétrico hacia arriba; vale 0 si primero toca el superior o se agota el tiempo). Toda variable en t usa solo datos ≤ t (ventana expansiva, shift(1) y fecha filed); los percentiles del P/E normalizado son expansivos. En P2 y P3 se toma una observación por empresa y trimestre calendario, y las ventanas de 3 años sin resultado completo se excluyen (censura).

Validación cronológica. Entrenamiento y prueba se separan con un **corte cronológico en 2018-12-31** —ajuste 2009-2018, prueba 2019+— con un **espacio de al menos N = 60 días hábiles**

entre ambos para que ninguna etiqueta del entrenamiento mire a la prueba. La estabilidad se verifica por **subperíodos** (2009-2012, 2013-2019, 2020-2021 y 2022+). La **línea base** es la tasa de toque por decil de volatilidad del último año (σ252): se parten los días del entrenamiento en 10 grupos por σ252 y la predicción para un día nuevo es la tasa de su grupo; da **AUC 0,591 en la prueba** (nb04 §4.5).

Métricas y qué queda para la entrega 2. Las métricas del SVM son AUC (probabilidad de ordenar correctamente un día que sí tocó frente a otro que no; 0,5 es azar), Brier (error cuadrático medio entre la probabilidad predicha y la realidad; menor es mejor) y calibración (si el modelo dice 30 %, ¿pasa cerca del 30 % de las veces?), por subperíodo. **La entrega 1 deja listas** la etiqueta, la línea base y la selección de variables (P4); **el SVM y su desempeño se calculan en la entrega 2**.

Detalle: https://github.com/louis97/asistente-financiero/blob/main/docs/entrega_1/04_enfoque_analitico.md

5. Recolección y diccionario de datos

Tres fuentes gratuitas alimentan el análisis, guardadas como instantáneas fechadas en data/snapshots/. De **yfinance** se descargan los precios semanales y diarios desde 2009-01 (21 344 filas semanales × 23 tickers; con y sin ajuste por dividendos, para separar el retorno total del múltiplo que vio el inversor). De **SEC EDGAR** se extraen los hechos XBRL de los 10-K (anual) y 10-Q (trimestral) con la fecha filed. De **Damodaran** se toman los múltiplos y márgenes por industria como contexto. El **P/E usa el EPS TTM**, construido a partir de los 10-Q y los 10-K: la autoridad publica cifras acumuladas (semestral y de nueve meses) y el cuarto trimestre se infiere del anual; el pipeline lo reconstruye y lo actualiza con cada publicación nueva, controlando la escala XBRL y las acciones implícitas (nb01 §4 y nb02 §2b). El universo son 21 empresas más el SPY y el XLP; KHC queda fuera por su historia desde 2015. La **cobertura TTM** es de 1.308 trimestres válidos sobre 1.434 (91,2 %); STZ queda fuera por falta de acciones y HSY solo tiene datos hasta 2015. En calidad, los precios semanales ajustados cierran con **0 nulos y 0 duplicados**; los saltos mayores que 5σ corresponden a movimientos reales (nb02 §3). Las 9 dimensiones de calidad (completitud, consistencia, conformidad, relevancia, precisión, procesabilidad, disponibilidad, temporalidad, credibilidad) y los 5 niveles (atributo, registro, columna, tabla, varias tablas) se auditan en nb02, y cada decisión lleva una línea de justificación.

Detalle: https://github.com/louis97/asistente-financiero/blob/main/docs/entrega_1/05_diccionario_datos.md · https://github.com/louis97/asistente-financiero/blob/main/notebooks/01_recoleccion.ipynb · https://github.com/louis97/asistente-financiero/blob/main/notebooks/02_calidad.ipynb

6. Entendimiento de los datos (EDA)

El EDA combina las cuatro vistas (univariada y multivariada, cada una gráfica y no gráfica): descriptivos robustos, histogramas con KDE, QQ-plot, volatilidad móvil, caída máxima, chi-cuadrado con V de Cramér, Spearman, VIF (mide colinealidad), PCA, prueba F de modelos anidados y clustermap. Cada prueba lleva su matriz de supuestos (supuesto → por qué importa → verificación → resultado → qué se hace si falla); con observaciones dependientes la decisión sale del IC95 por bootstrap, no del p-value clásico. Los resultados por hipótesis están en la tabla de la sección 4 y salen de data/resultados/nb03.json, nb04.json y nb04_p4.json.

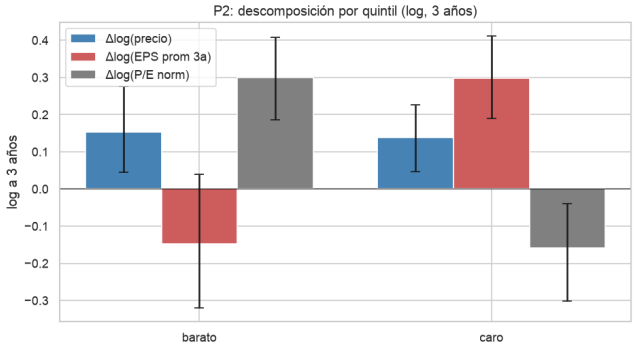


Figura 2. P2: Δlog(P/E normalizado) a 3 años por quintil. El quintil **barato (Q1)** sube su múltiplo con **+0,153 anualizada en log** frente al **caro (Q5)**; IC95 por empresa [+0,091; +0,221]. **Compatible con trampa de valor, no la afirma**: precio +0,15 (IC95 excluye 0) y EPS promedio −0,15 (IC95 cruza 0). nb04 §2.7–§2.8.

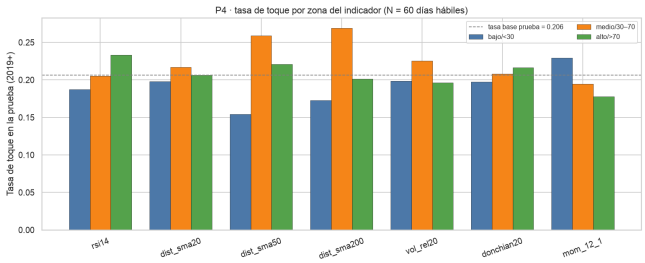


Figura 3. P4: ΔAUC por indicador técnico sobre la línea base por decil de σ252. Los siete IC95 bilaterales (Bonferroni ≈ 99,3 %) cruzan 0; mayor en valor absoluto dist_sma50 (ΔAUC −0,024, IC [−0,066; +0,026]) y más estrecho vol_rel20 (ΔAUC −0,001, IC [−0,011; +0,010]). Línea base **AUC 0,591** con N = 60. variables_svm = {|r_t|, σ20/σ252, σ252} (solo magnitud). nb04 §5.3.

Dos lecturas requieren contexto. En **P2**, la descomposición compatible con trampa de valor no se afirma porque el IC95 del EPS cruza 0. En **P4**, los siete indicadores técnicos no mejoran la AUC sobre la línea base por decil de σ, por eso las variables del SVM quedan solo de magnitud. Como control de multiplicidad, Holm al 0,05 sobre las 13 pruebas con decisión de negocio deja rechazando a las cuatro que ya rechazaban (P2, P5, P6 diaria y P6 semanal); ninguna decisión cambia (nb04 §8).
Detalle: https://github.com/louis97/asistente-financiero/blob/main/notebooks/03_eda_univariado.ipynb · https://github.com/louis97/asistente-financiero/blob/main/notebooks/04_eda_multivariado.ipynb

7. Conclusiones iniciales e insights

Hallazgos (asociaciones, no causas). En consumo defensivo, las caídas semanales fuertes no son más frecuentes que las que daría una normal medida igual (P1); el quintil barato por P/E normalizado sube más su múltiplo que el caro a 3 años, con descomposición compatible con trampa de valor (P2); el barato no gana al XLP a 3 años (P3); ningún indicador técnico mejora la AUC sobre la línea base por decil de σ (P4); el XLP agrega ΔR^2 mediano 0,225 al SPY (P5, confirmatoria); la turbulencia se agrupa, con magnitud incierta (P6). **Insights.** La lectura fundamental del “barata frente a su historia” usa el percentil del P/E normalizado con advertencia de posible deterioro de utilidades; el exceso sobre el XLP no entra como señal, solo como contexto; los niveles van en k · σ252 diaria con etiqueta a N = 60 días hábiles; la simulación remuestrea bloques de semanas de la acción y del XLP a la vez; variables_svm = {|r_t|, σ20/σ252, σ252} (solo magnitud) frente a línea base AUC 0,591. **Limitaciones:** una sola industria piloto (21 empresas); sesgo de supervivencia (pesa más a 3 años); historia desde 2009 (P/E normalizado a 3 años, no 5-10); EPS TTM con 91,2 % de cobertura; ventanas de 3 años solapadas (IC por empresa); P5 confirmatoria; P4 con fuga de selección, mitigada en la entrega 2; **validación del mockup con un solo inversor, asíncrona, y KPI 1, 2 y 5 sin línea base**. **Acciones próximas:** entrenar el SVM con corte cronológico, implementar la simulación por bloques, **validar un prototipo navegable con más usuarios** y medir los KPI, y replicar el pipeline en una segunda industria. Detalle: https://github.com/louis97/asistente-financiero/blob/main/docs/entrega_1/07_conclusiones.md