Asistente Bursátil para el inversor value colombiano — Entrega 1

Louis Gualtero · MINE-4101 Ciencia de Datos Aplicada · Universidad de los Andes

Repositorio: https://github.com/louis97/asistente-financiero/tree/entrega-1 · **Video:** (pendiente)

1. Problema y negocio

El inversor value colombiano que compra acciones de EE.UU. actúa como enrutador manual de datos: usa un screener, otra pantalla para fundamentales y otra para el gráfico, y no tiene dónde anotar sus decisiones. Con la evidencia cualitativa de una entrevista y un formulario (un participante más el autor): **de 2 a 15 cambios de pantalla por activo**, **2 a 3 horas** para actualizar el análisis tras cada reporte trimestral y riesgo medido "a ojo". El contexto crece: el volumen del Mercado Global Colombiano pasó de $1,60 a $3,75 billones entre 2024 y 2025 (+134 %, BVC). Objetivo: una vista única con niveles de compra y venta, y probabilidades explicables. KPIs: tiempo por activo < 5 min, 1 cambio de pantalla, latencia tras reporte ≤ 1 día, 100 % de decisiones registradas.

Detalle: 01_negocio.md

2. Ideación y mockup

El producto entrega seis niveles definidos por el usuario (tres de entrada, tres de salida), cada uno en precio y en múltiplo, con tres lecturas: fundamental (percentil en la historia y la industria), técnica (probabilidad de un SVM frente a su línea base GBM) y probabilística (Monte Carlo con y sin el factor del sector), más un panel de riesgo (volatilidad, VaR/ES, beta, drawdown, Merton). Los niveles por múltiplo se recalculan cuando EDGAR publica un reporte (precio = múltiplo × EPS). El prototipo usa valores ilustrativos. **La validación con el stakeholder está pendiente**: el guion está listo y el registro se completará tras la sesión; no se reportan resultados de validación.

Detalle: 02_ideacion.md

3. Aspectos éticos y legales

Los riesgos altos son tres. **Regulación de la asesoría** (Ley 964 de 2005): el producto no recomienda "compra" ni "venta", los niveles los define el usuario y cada pantalla dice que no es asesoría. **Transparencia**: SVM lineal con coeficientes legibles y probabilidad siempre junto a su línea base y su error histórico. **Look-ahead y data snooping**: fundamentales con fecha `filed`, ventana expansiva, purga y embargo. Además: anonimización del participante (Ley 1581 de

XXXX | Precio: $100.00 | Último reporte (filed): 2026-08-01

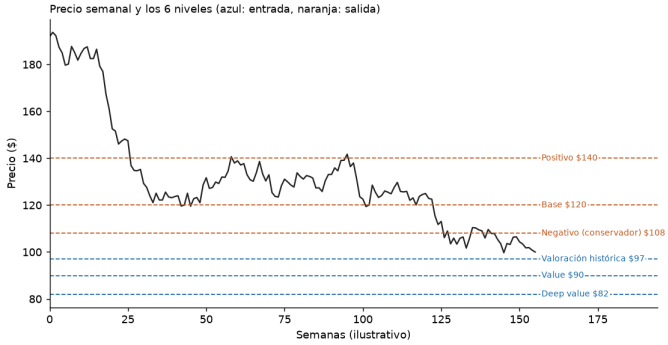
Niveles por múltiplo recalculados tras el reporte (precio = múltiplo x EPS)

MOCKUP - ILUSTRATIVO: TODOS LOS VALORES SON INVENTADOS, NO PROVIENEN DE DATOS REALES

Seis niveles x tres lecturas (fundamental comparativa, técnica SVM, probabilística) - ▲ diverge: el nivel en precio y el nivel en múltiplo no coinciden (el usuario decide cuál conservar)

Nivel	Tipo	Precio	Múltiplo implícito (P/E)	Percentil histórico	Percentil industria	P(SVM) [intervalo] · base GBM (solo entradas)	P(Monte Carlo) con vs sin componente sector
Deep value	Entrada	$82	11.0x	p8	p15	0.31 [0.24-0.38] · GBM 0.22	con sector 0.28 · sin sector 0.11
Value ▲ diverge	Entrada	$90	12.1x	p18	p28	0.47 [0.40-0.54] · GBM 0.38	con sector 0.44 · sin sector 0.19
Valoración histórica	Entrada	$97	13.0x	p45	p52	0.62 [0.55-0.69] · GBM 0.55	con sector 0.60 · sin sector 0.31
Negativo (conservador)	Salida	$108	14.5x	p62	p60	n/a	con sector 0.55 · sin sector 0.40
Base	Salida	$120	16.1x	p78	p71	n/a	con sector 0.36 · sin sector 0.21
Positivo	Salida	$140	18.8x	p92	p88	n/a	con sector 0.15 · sin sector 0.09

Precio semanal y los 6 niveles (azul: entrada, naranja: salida)



Desempeño histórico (ilustrativo)

AUC walk-forward: SVM / GBM	**0.61 / 0.54**
Brier: SVM / GBM	**0.21 / 0.24**
% de errores (falsas entradas, umbral 0.5)	**37%**

Panel de riesgo (ilustrativo)

Volatilidad anualizada (hist / EWMA / GARCH)	**28% / 31% / 30%**
VaR 95% / 99% semanal (hist)	**-6.1% / -9.4%**
VaR paramétrico 95% / 99% semanal	**-5.8% / -8.3%**
Expected Shortfall 95%	**-8.0%**
Beta / alfa vs SPY (anual)	**1.12 / +1.8%**
Beta vs ETF sectorial · R2 (parte sistemática)	**0.95 · 0.58**
Sharpe (anualizado)	**0.42**
Max drawdown (ventana)	**-34%**
Merton: PD = N(-d2)	**0.4%**

Indicadores que más pesaron en P(SVM) del nivel Deep value (ilustrativo): RSI(14) bajo (+), distancia a SMA(50) (+), volumen relativo (-).
Un score es una probabilidad con su intervalo, su línea base y sus errores históricos; no es una señal.

Editar nivel Registrar decisión (botones ilustrativos: no hacen nada en el wireframe)

No es asesoría de inversión. El contenido no constituye una recomendación profesional en los términos del art. 2.40.1.1.2 del Decreto 2555 de 2010.
Las probabilidades son estimaciones con incertidumbre, no señales de compra/venta. TODO ILUSTRATIVO.

Figura 1: Mockup del dashboard (valores ilustrativos)

2012), términos de uso de yfinance, EDGAR y Damodaran, y sesgo de supervivencia de 30 emisores vigentes.

Detalle: 03_etica_legal.md

4. Enfoque analítico

Tres preguntas de negocio (¿es razonable el nivel?, ¿compro ya o espero?, ¿qué tan probable es el objetivo?) se traducen en hipótesis con H0 y H1 que se pueden refutar: técnicas (HT0 caminata aleatoria, HT1 SVM frente a GBM, HT2 señal de indicadores), fundamentales (HF1 y HF2 reversión de múltiplos) y probabilísticas (HP0 colas pesadas, HP3 efecto del sector). La etiqueta es una **triple barrera solo-largo** (±k·σ, horizonte de N semanas; en el EDA se eligió k = 1, N = 12). Validación **walk-forward con purga y embargo**, con cuatro líneas base obligatorias (GBM, clase mayoritaria, regresión logística, momentum 12-1) y reglas de decisión fijadas de antemano: una hipótesis solo se declara apoyada si el IC bootstrap excluye el valor nulo. Todo es asociativo, no causal.

Detalle: 04_enfoque_analitico.md

5. Recolección y calidad de datos

Tres fuentes gratuitas: yfinance (precios semanales y mensuales desde 2009), SEC EDGAR (hechos XBRL con fecha `filed`) y Damodaran (múltiplos por industria). Universo: 30 acciones grandes de EE.UU. y 4 ETF (SPY, XLK, XLP, XLF), con 27 326 filas en el panel semanal. Calidad: precios sin nulos, duplicados ni semanas faltantes; 73 saltos > 5σ que son movimientos reales. La utilidad bruta está presente en solo 14 de 30 emisores (ausente en 16) y las financieras no tienen utilidad operativa. Las cifras de EDGAR coinciden en 6 de 6 con el 10-K de AAPL, KO y JPM.

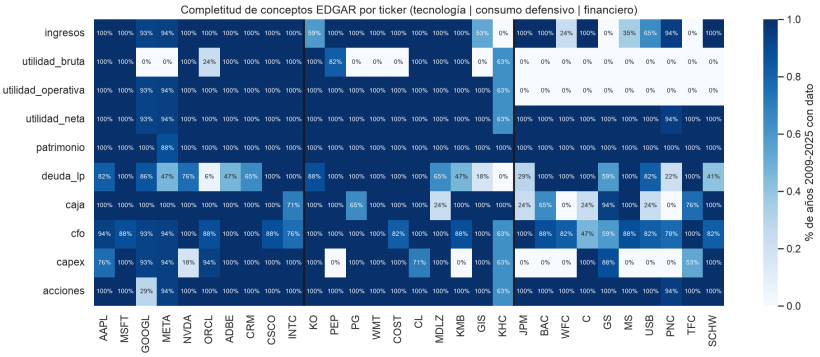


Figura 2: Completitud de conceptos de EDGAR

Detalle: 05_diccionario_datos.md · nb 02

6. Análisis exploratorio (EDA)

Volatilidad y colas. La volatilidad se agrupa y las colas son pesadas: curtosis en exceso mediana 4.63, ν mediano 4.15 (ν < 10 en 34 de 34 series); GARCH(1,1)-t supera a la volatilidad

constante fuera de muestra en 28 de 34 series. Un GBM normal no describe el riesgo (HP0 apoyada).

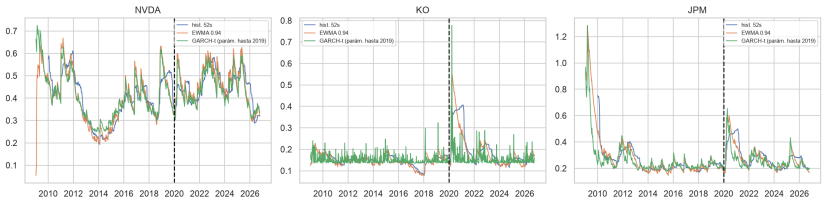


Figura 3: GARCH-t frente a EWMA

Dirección del precio. ADF no rechaza la raíz unitaria en 33 de 34 log-precios y |ρ lag 1| mediana es 0.068 (HT0 apoyada). Con k = 1, N = 12, un GBM con μ = 0 sobreestima la clase 1 en 9.5 pp (0.178 observada frente a 0.274); con deriva pasada la brecha es −0.8 pp.

Indicadores técnicos. La señal es débil e inestable: AUC por indicador de 0.496 a 0.514, ningún IC por bloques excluye 0.5. Por régimen sube a 0.64–0.79 solo en COVID y 2022, eventos únicos (HT2 no concluyente, HT3 no apoyada).

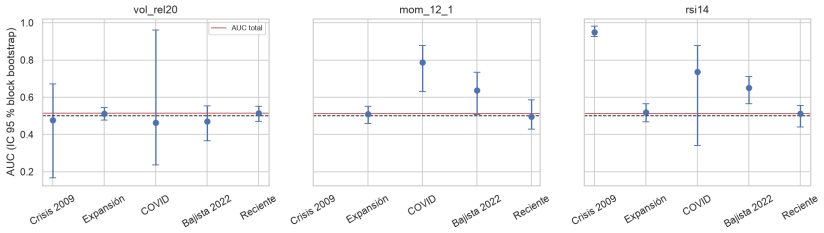


Figura 4: AUC por régimen

Sector. El R^2 mediano del modelo de índice único con el ETF sectorial es 0.525 (financieras 0.700, tecnología 0.387); las industrias se agrupan solas (ARI 0.898) (HP3 apoyada con matices).

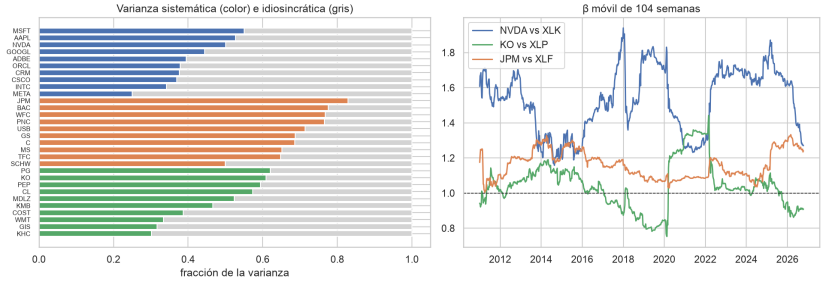


Figura 5: Índice único: R^2 por ticker

Múltiplos y VaR. Solo 7 de 29 tickers muestran reversión del P/E o P/B (HF1 no apoyada) y 10 de 29 con el múltiplo relativo (HF2 parcial). El VaR 95 % fuera de muestra tiene 7.49 % de excepciones con GARCH-t y 6.78 % con el histórico, frente al 5 % esperado (HP1 parcial).

Detalle: 03_eda_series · 04_eda_relaciones · 07_conclusiones.md

7. Conclusiones e insights

El EDA no muestra que los indicadores técnicos, por sí solos, separen las clases; la probabilidad de la etiqueta depende de σ (de 20.6 % en el decil 1 a 7.8 % en el decil 10) y del régimen. Decisiones de diseño: etiqueta k = 1, N = 12; simulación con GARCH-t e innovaciones t, no GBM normal; línea base GBM con deriva ≤ t; múltiplos solo como contexto; VaR 99 % histórico con advertencia. **Limitaciones**: muestra desde 2009, pocos eventos de régimen, sesgo de supervivencia y fundamentales incompletos. **Próximas acciones**: entrenar el SVM con walk-forward (HT1 queda preparada, no probada; se espera una mejora pequeña o nula), añadir rasgos de régimen calculados hacia atrás, construir el Monte Carlo y validar el mockup con el stakeholder.

Detalle: 07_conclusiones.md